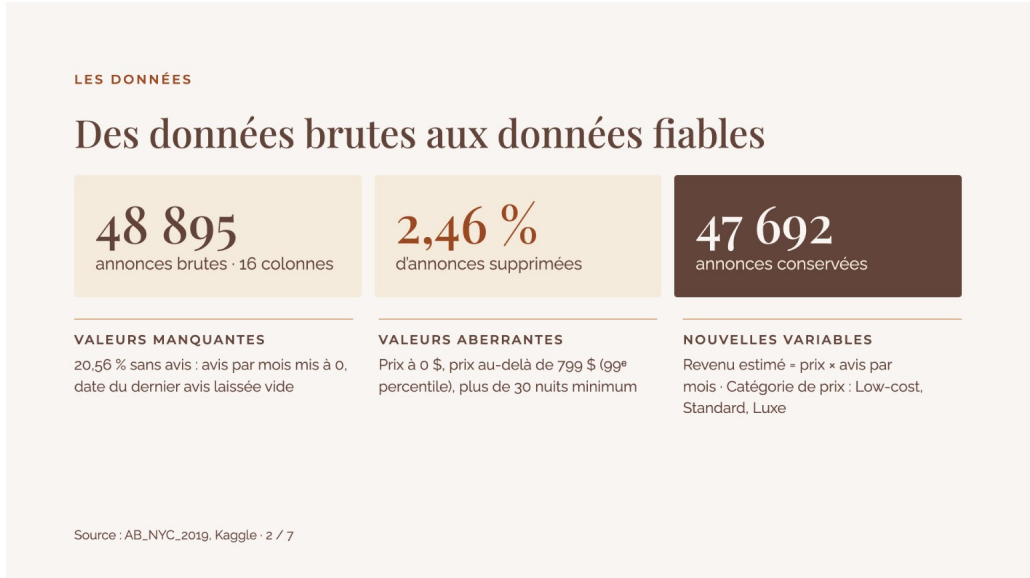


Bonjour. Pour ce projet, j'ai joué le rôle d'une data analyst dans un fonds d'investissement qui veut se lancer dans la location courte durée à New York. Le directeur d'investissement m'a posé une question simple : « Montrez-moi les biens sous-évalués, et prouvez-le. » Mon objectif était donc de passer d'une donnée brute, 48 895 annonces Airbnb, à un outil qui décrit le marché, prédit le juste prix d'une nuit et repère les opportunités.



Le jeu de données vient de Kaggle : 48 895 annonces Airbnb à New York. Avant de modéliser, j'ai fait un diagnostic puis un nettoyage. Les valeurs manquantes concernaient surtout les 20 % de logements sans aucun avis : j'ai mis leurs avis par mois à 0, ce qui est logique, et j'ai laissé la date du dernier avis vide, car on ne peut pas inventer une date. J'ai supprimé les valeurs aberrantes : les prix à 0 dollar, impossibles, les prix au-delà du 99e percentile, soit 799 dollars, et les logements qui exigent plus de 30 nuits, car ce n'est plus de la location courte durée. Au total, je n'ai supprimé que 2,46 % des annonces. Enfin, j'ai créé deux variables : le revenu estimé, qui est un proxy basé sur les avis, et la catégorie de prix, en trois groupes de taille égale.

LE MARCHÉ

Le quartier le plus cher n’est pas le plus rentable

Arrondissement	Prix médian	Revenu estimé
Manhattan	149 $	39,60 $
Brooklyn	90 $	37,20 $
Queens	75 $	55,65 $
Bronx	65 $	53,72 $
Staten Island	75 $	70,59 $

Plus cher, mais moins loué

Manhattan a le prix le plus haut, mais l’un des revenus estimés les plus bas. Le Queens, le Bronx et Staten Island sont moins chers et plus souvent loués.

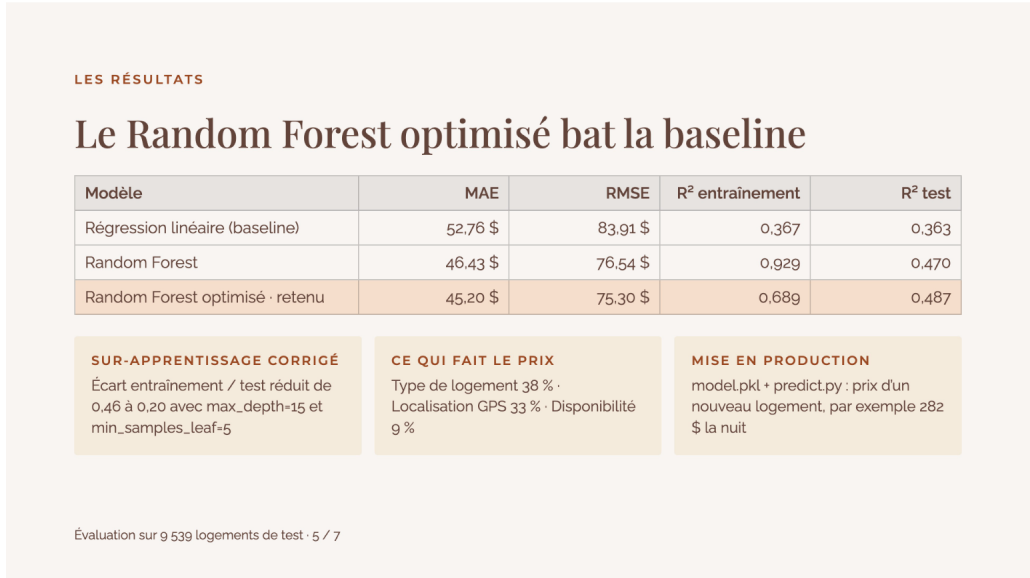
Un logement entier coûte 160 $ en médiane, contre 70 $ pour une chambre privée.

Valeurs médianes par nuit · Revenu estimé = prix × avis par mois · 3 / 7

Voici le principal enseignement de l’analyse exploratoire. J’ai utilisé la médiane, parce qu’elle représente le logement typique sans être déformée par quelques logements très chers. Manhattan a le prix médian le plus élevé, 149 dollars la nuit, mais l’un des revenus estimés les plus faibles, environ 40 dollars. À l’inverse, le Queens, le Bronx et Staten Island sont moins chers mais reçoivent plus d’avis par mois, donc ils sont loués plus souvent. Attention : Staten Island ne compte que 365 annonces, son résultat est moins fiable. Le type de logement compte aussi beaucoup : un logement entier coûte plus du double d’une chambre privée.



Pour prédire le prix, j'ai utilisé l'apprentissage supervisé : le modèle apprend à partir d'exemples dont on connaît le prix. La target, c'est le prix. Les features, ce sont les caractéristiques du logement. J'ai encodé les variables texte avec get_dummies, car un modèle ne comprend que des nombres, puis découpé les données en 80 % pour l'entraînement et 20 % pour le test, sur des logements que le modèle n'a jamais vus. Le point clé, c'est la fuite de données. Le sujet mentionnait le revenu estimé, mais j'ai aussi exclu la catégorie de prix, car elle est construite à partir du prix : savoir qu'un logement est « Luxe » revient à savoir qu'il coûte plus de 150 dollars. Mon test : pour un nouveau logement dont je ne connais pas le prix, est-ce que j'aurais cette information ? Si non, c'est une fuite.



J'ai évalué les modèles avec trois métriques. La MAE, c'est l'erreur moyenne en dollars. La RMSE pénalise davantage les grosses erreurs. Le R^2 mesure à quel point le modèle fait mieux que quelqu'un qui répondrait toujours le prix moyen. La régression linéaire additionne l'effet de chaque variable séparément, alors que le Random Forest peut combiner les variables, par exemple quartier et type de logement. C'est pour ça qu'il est plus performant. Mais le premier Random Forest faisait du sur-apprentissage : 0,93 de R^2 à l'entraînement contre 0,47 en test, il avait mémorisé les données. En limitant la profondeur des arbres, l'écart a fondu et le score de test s'est encore amélioré : 0,487, et 45 dollars d'erreur moyenne. Un R^2 de 0,49 reste modeste, car le dataset ne contient pas la surface ni le nombre de chambres. Enfin, j'ai sérialisé le modèle avec joblib au format pickle, pour le réutiliser sans le ré-entraîner, avec un script predict.py.



Voici l'application métier. Pour chaque logement, je compare le prix affiché au prix prédit par le modèle. Si le prix prédit est bien plus haut, le logement est sous-évalué. J'ai travaillé sur le jeu de test, parce que le modèle n'a jamais vu ces logements : son estimation est honnête. Et j'ai gardé uniquement les logements avec au moins 10 avis, pour écarter les annonces inactives. Résultat : les 10 biens les plus sous-évalués sont tous des logements entiers, surtout à Manhattan. Ils sont affichés en moyenne à 115 dollars la nuit, alors que le modèle estime leur juste prix à 294 dollars, soit environ 180 dollars d'écart par nuit. Si on me demande pourquoi c'est Manhattan alors que ma première recommandation parlait du Queens : ce sont deux questions différentes. Le Queens, c'est là où les logements sont le plus loués. Manhattan, c'est là où les prix sont les plus élevés, donc là où les écarts peuvent être les plus grands.



Pour conclure, ma recommandation au fonds tient en trois points. Un : des opportunités immédiates. Les biens du Top 10 sont affichés bien en dessous de leur valeur de marché. En alignant leur prix sur l'estimation du modèle, on gagne environ 180 dollars par nuit, soit environ 18 000 dollars par an et par bien sur une base de 100 nuits louées. Deux : une stratégie de fond. L'analyse exploratoire montre que les logements entiers dans le Queens offrent le meilleur revenu estimé sur un marché fiable, deux fois et demie celui de Manhattan. Trois : de la prudence. Le modèle se trompe en moyenne de 45 dollars et ne connaît ni la surface ni l'état du logement. Un bien peut être bon marché pour une bonne raison, donc chaque opportunité doit être vérifiée par une visite. Tout le projet est disponible sur mon GitHub. Merci, je suis prête pour vos questions.